

# Методы машинного обучения. Обучение без учителя: байесовские латентные модели

Воронцов Константин Вячеславович

[www.MachineLearning.ru/wiki?title=User:Vokov](http://www.MachineLearning.ru/wiki?title=User:Vokov)

вопросы к лектору: [k.v.vorontsov@yandex.ru](mailto:k.v.vorontsov@yandex.ru)

материалы курса:

[github.com/MSU-ML-COURSE/ML-COURSE-23-24](https://github.com/MSU-ML-COURSE/ML-COURSE-23-24)

орг.вопросы по курсу: [ml.cmc@mail.ru](mailto:ml.cmc@mail.ru)

## Выявление структуры данных на основе сходства:

- кластеризация (clustering) и квантизация (quantization)
- оценивание плотности распределения (density estimation)
- одноклассовая классификация (anomaly detection)

## Преобразование признакового пространства:

- метод главных компонент (principal components analysis)
- автокодировщики (autoencoders)
- многомерное шкалирование (multidimensional scaling)
- матричные разложения (matrix factorization)
- тематическое моделирование (topic modeling)

## Поиск взаимосвязей в данных или синтез учителя:

- частичное обучение (semi-supervised learning)
- поиск ассоциативных правил (association rule learning)
- самостоятельное обучение (self-supervised learning)

- 1 **Байесовские модели с латентными переменными**
  - Байесовское обучение с регуляризацией
  - Примеры задач
  - Байесовская теория EM-алгоритма
- 2 **Разделение смеси распределений**
  - Постановка задачи и EM-алгоритм
  - Регуляризованный EM-алгоритм
  - Примеры регуляризации
- 3 **Вероятностное тематическое моделирование**
  - Постановка задачи и EM-алгоритм
  - Регуляризованный EM-алгоритм
  - Примеры регуляризации

## Напоминание. Вероятностные модели порождения данных

**Дано:**

$X = (x_1, \dots, x_\ell)$  — исходные данные, *наблюдаемые переменные*

**Найти:**

$p(X|\Omega)$  — модель порождения данных, с параметром  $\Omega$

$p(X|\Omega) = \prod_{i=1}^{\ell} p(x_i|\Omega)$  — в случае простой (i.i.d.) выборки

**Критерии максимизации:**

— *правдоподобия* (Maximum Likelihood Estimate, MLE):

$$\ln p(X|\Omega) = \sum_{i=1}^{\ell} \ln p(x_i|\Omega) \rightarrow \max_{\Omega}$$

— *апостериорной вероятности* (Maximum a Posteriori, MAP):

$$\ln p(X, \Omega) = \ln p(X|\Omega)p(\Omega|\gamma) = \sum_{i=1}^{\ell} \ln p(x_i|\Omega) + \ln p(\Omega|\gamma) \rightarrow \max_{\Omega}$$

где  $R(\Omega) = \ln p(\Omega|\gamma)$  играет роль регуляризатора.

## Порождающая модель с латентными переменными

**Дано:**

$X = (x_1, \dots, x_\ell)$  — исходные данные, *наблюдаемые переменные*

$Z = (z_1, \dots, z_m)$  — *латентные (скрытые) переменные*

**Найти:**

$p(X, Z|\Omega)$  — модель совместного порождения наблюдаемых данных и скрытых переменных, с параметром  $\Omega$

**Критерий:**

максимум правдоподобия (Maximum Likelihood Estimate, MLE):

$$\ln p(X|\Omega) = \ln \int_Z p(X, Z|\Omega) dZ \rightarrow \max_{\Omega}$$

Для дискретных переменных  $Z$  вместо интеграла  $\int_Z$  сумма  $\sum_Z$

Договоримся далее  $dZ$  опускать

---

*Bishop C. M. Pattern recognition and machine learning. Springer, 2006.*

# 1. Разделение смеси распределений — мягкая кластеризация

$X = (x_1, \dots, x_\ell)$  — исходные данные, *наблюдаемые переменные*

$Z = (j_1, \dots, j_\ell)$  — компонента смеси  $j_i$  порождает объект  $x_i$

Порождающая модель смеси  $k$  вероятностных распределений:

$$p(x) = \sum_{j=1}^k p(x, j) = \sum_{j=1}^k p(j)p(x|j) = \sum_{j=1}^k w_j \varphi(x, \theta_j)$$

$\Omega = (w_j, \theta_j)_{j=1}^k$  — параметры модели:  $w_j = p(j)$ ,  $\varphi(x, \theta_j) = p(x|j)$

Порождающая модель наблюдаемых и скрытых *i.i.d.* данных:

$$p(X, Z|\Omega) = \prod_{i=1}^{\ell} p(x_i, j_i) = \prod_{i=1}^{\ell} p(j_i)p(x_i|\theta_{j_i}) = \prod_{i=1}^{\ell} w_{j_i} \varphi(x_i, \theta_{j_i})$$

Задача разделения смеси — максимизация  $\log$  правдоподобия:

$$\ln p(X|\Omega) = \ln \prod_{i=1}^{\ell} p(x_i) = \sum_{i=1}^{\ell} \ln \sum_{j=1}^k w_j \varphi(x_i, \theta_j) \rightarrow \max_{\Omega}$$

## 2. Тематическое моделирование — мягкая би-кластеризация

$X = (w_1|d_1, \dots, w_n|d_n)$  — слова  $w_i \in W$  в документах  $d_i \in D$   
 $Z = (t_1, \dots, t_n)$ , скрытая тема  $t_i \in T$  порождает слово  $w_i|d_i$

Вероятностная языковая модель порождения слов документа:

$$p(w|d) = \sum_{t \in T} p(w, t|d) = \sum_{t \in T} p(w|t)p(t|d) = \sum_{t \in T} \phi_{wt}\theta_{td}$$

$\Omega = (\Phi, \Theta)$  — параметры модели:  $\phi_{wt} = p(w|t)$ ,  $\theta_{td} = p(t|d)$

Порождающая модель наблюдаемых и скрытых *i.i.d.* данных:

$$p(X, Z|\Omega) = \prod_{i=1}^n p(w_i, t_i|d_i) = \prod_{i=1}^n \phi_{w_i t_i} \theta_{t_i d_i}$$

Задача разделения смеси тем в каждом документе:

$$\ln p(X|\Omega) = \ln \prod_{i=1}^n p(w_i|d_i) = \sum_{i=1}^n \ln \sum_{t \in T} \phi_{w_i t} \theta_{t d_i} \rightarrow \max_{\Omega}$$

## Байесовская порождающая модель с латентными переменными

$X = (x_1, \dots, x_\ell)$  — исходные данные, наблюдаемые переменные

$Z = (z_1, \dots, z_m)$  — латентные (скрытые) переменные

$p(X, Z|\Omega)$  — модель наблюдаемых и скрытых переменных

$p(\Omega|\gamma)$  — априорное распределение с гиперпараметрами  $\gamma$

Задача: по  $X$  найти  $\Omega$ .

Апостериорное распределение, по формуле Байеса:

$$p(\Omega|X, \gamma) \propto p(X|\Omega) p(\Omega|\gamma) = \int_Z p(X, Z|\Omega) p(\Omega|\gamma)$$

Принцип максимума апостериорной вероятности:

$$\ln p(\Omega|X, \gamma) = \ln \int_Z p(X, Z|\Omega) + \underbrace{\ln p(\Omega|\gamma)}_{R(\Omega)} \rightarrow \max_{\Omega}$$

$R(\Omega) = \ln p(\Omega|\gamma)$  — байесовский регуляризатор, хотя

$R(\Omega)$  может и не иметь вероятностной интерпретации.



## Общий ЕМ-алгоритм для задачи со скрытыми переменными

**Теорема.** Точка  $\Omega$  локального максимума регуляризованного маргинализованного правдоподобия (Marginal log-Likelihood)

$$\ln \int_Z p(X, Z|\Omega) + R(\Omega) \rightarrow \max_{\Omega} \quad (\text{RML})$$

удовлетворяет системе уравнений, решение которой методом простых итераций сводится к чередованию двух шагов:

$$\text{Е-шаг: } q(Z) = p(Z|X, \Omega);$$

$$\text{М-шаг: } \int_Z q(Z) \ln p(X, Z|\Omega) + R(\Omega) \rightarrow \max_{\Omega}.$$

Общий ЕМ-алгоритм используется не только для разделения смесей, но и в анализе сигналов, изображений, текстов и др.

---

A.P.Dempster, N.M.Laird, D.B.Rubin. Maximum likelihood from incomplete data via the EM algorithm. 1977.

## Доказательство теоремы

Необходимые условия локального экстремума:

$$\frac{\partial}{\partial \Omega} \left( \ln \int_Z p(X, Z | \Omega) + R(\Omega) \right) = \frac{1}{p(X | \Omega)} \int_Z \frac{\partial p(X, Z | \Omega)}{\partial \Omega} + \frac{\partial R(\Omega)}{\partial \Omega} = 0$$

По формуле условной вероятности  $p(X | \Omega) = \frac{p(X, Z | \Omega)}{p(Z | X, \Omega)}$ , подставляем:

$$\begin{aligned} \int_Z \frac{p(Z | X, \Omega)}{p(X, Z | \Omega)} \frac{\partial p(X, Z | \Omega)}{\partial \Omega} + \frac{\partial R(\Omega)}{\partial \Omega} &= 0 \\ \int_Z \underbrace{p(Z | X, \Omega)}_{q(Z)} \frac{\partial}{\partial \Omega} \ln p(X, Z | \Omega) + \frac{\partial R(\Omega)}{\partial \Omega} &= 0 \end{aligned}$$

Это уравнение совпадает с необходимым условием локального экстремума для задачи M-шага, при этом  $q(Z)$  рассматривается как переменная, не зависящая от  $\Omega$ .



## Ещё более общий EM-алгоритм и его сходимость

**Теорема.** Значение маргинализованного правдоподобия

$$\ln \int_Z p(X, Z|\Omega) + R(\Omega) \rightarrow \max_{\Omega} \quad (\text{RML})$$

не убывает на каждом шаге итерационного процесса

$$\text{Е-шаг: } \text{KL}(q(Z) \parallel p(Z|X, \Omega)) \rightarrow \min_q;$$

$$\text{М-шаг: } \int_Z q(Z) \ln p(X, Z|\Omega) + R(\Omega) \rightarrow \max_{\Omega}.$$

$q(Z) = p(Z|X, \Omega)$  является точным решением задачи Е-шага.

Минимизация KL-дивергенции на Е-шаге используется в случаях, когда не удаётся вычислить  $p(Z|X, \Omega)$  в явном виде.

Сходимость в слабом смысле: глобальный max не гарантируется.

## Доказательство теоремы

По формуле условной вероятности  $p(X|\Omega) = \frac{p(X, Z|\Omega)}{p(Z|X, \Omega)}$ .

Для произвольного распределения  $q(Z)$

$$\begin{aligned} \ln p(X|\Omega) &= \int_Z q(Z) \ln p(X|\Omega) = \int_Z q(Z) \ln \frac{p(X, Z|\Omega)}{p(Z|X, \Omega)} = \\ &= \underbrace{\int_Z q(Z) \ln \frac{p(X, Z|\Omega)}{q(Z)}}_{L(q, \Omega)} + \underbrace{\int_Z q(Z) \ln \frac{q(Z)}{p(Z|X, \Omega)}}_{\text{KL}(q(Z) \| p(Z|X, \Omega))} \geq 0 \end{aligned}$$

Максимизируем достижимую нижнюю оценку RML то по  $q$ , то по  $\Omega$ :

$$\text{Е-шаг: } L(q, \Omega) + \cancel{R(\Omega)} \rightarrow \max_q \Leftrightarrow \text{KL}(q(Z) \| p(Z|X, \Omega)) \rightarrow \min_q$$

$$\text{М-шаг: } L(q, \Omega) + R(\Omega) \rightarrow \max_{\Omega} \Leftrightarrow \int_Z q(Z) \ln p(X, Z|\Omega) + R(\Omega) \rightarrow \max_{\Omega}$$

На каждом шаге значение функционала может только возрастать, откуда и следует сходимость в слабом смысле. ■

## Задача разделения смеси: применение общего ЕМ-алгоритма

$X = (x_1, \dots, x_\ell)$  — исходные данные, *наблюдаемые переменные*

$Z = (j_1, \dots, j_\ell)$  — *компоненты смеси  $j_i$ , порождающие объекты  $x_i$*

$$p(X, Z|\Omega) = \prod_{i=1}^{\ell} p(x_i, j_i|\Omega) = \prod_{i=1}^{\ell} p(j_i)p(x_i|\theta_{j_i}) = \prod_{i=1}^{\ell} w_{j_i} \varphi(x_i, \theta_{j_i})$$

**Е-шаг:** в силу независимости элементов выборки и формулы Байеса

$$q(Z) = p(Z|X, \Omega) = \prod_{i=1}^{\ell} p(j_i|x_i, \Omega); \quad p(j|x, \Omega) = \frac{p(x, j|\Omega)}{p(x|\Omega)} = \frac{w_j \varphi(x, \theta_j)}{\sum_t w_t \varphi(x, \theta_t)}$$

**М-шаг:** подставим  $q(Z)$  и  $p(X, Z|\Omega)$  в общую формулу М-шага:

$$\begin{aligned} & \sum_Z q(Z) \ln p(X, Z|\Omega) + R(\Omega) = \\ & = \sum_{j_1=1}^k \cdots \sum_{j_\ell=1}^k \prod_{t=1}^{\ell} p(j_t|x_t, \Omega) \sum_{i=1}^{\ell} \ln p(x_i, j_i|\Omega) + R(\Omega) = \\ & = \sum_{i=1}^{\ell} \sum_{j=1}^k \underbrace{p(j|x_i, \Omega)}_{g_{ij}} \underbrace{\ln p(x_i, j|\Omega)}_{w_j \varphi(x_i, \theta_j)} + R(\Omega) \rightarrow \max_{\Omega}, \quad \Omega = (w_j, \theta_j)_{j=1}^k \end{aligned}$$

## ЕМ-алгоритм: вывод формул М-шага

М-шаг распадается на  $2k$  подзадач по  $w_j, \theta_j, j = 1, \dots, k$ :

$$\sum_{j=1}^k \sum_{i=1}^{\ell} \left( g_{ij} \ln w_j + g_{ij} \ln \varphi(x_i, \theta_j) \right) + R(\Omega) \rightarrow \max_{\Omega}$$

Необходимые условия локального экстремума:

$$\begin{cases} \frac{\partial}{\partial \theta_j} \left( \sum_{i=1}^{\ell} g_{ij} \ln \varphi(x_i, \theta_j) + R(\Omega) \right) = 0; \\ \frac{\partial}{\partial w_j} \left( \sum_{i=1}^{\ell} g_{ij} \ln w_j + R(\Omega) + \left( 1 - \sum_{j=1}^k w_j \right) \lambda_j - w_j \mu_j \right) = 0; \\ w_j \geq 0, \quad \sum_{j=1}^k w_j = 1, \quad w_j \mu_j = 0, \quad \mu_j \geq 0 \end{cases}$$

Относительно  $w_j$  решение аналитическое, из условий ККТ:

$$w_j = \text{norm}_j \left( \sum_{i=1}^{\ell} g_{ij} + w_j \frac{\partial R}{\partial w_j} \right), \quad j = 1, \dots, k.$$

## ЕМ-алгоритм для разделения смеси распределений

Задача разделения смеси:  $(X, Z) = (x_i, j_i)_{i=1}^{\ell}$ ,  $\Omega = (w_j, \theta_j)_{j=1}^k$

**Теорема.** Точка  $\Omega$  локального максимума (RML)

$$\ln \sum_Z p(X, Z | \Omega) + R(\Omega) = \sum_{i=1}^{\ell} \ln \sum_{j=1}^k w_j \varphi(x_i, \theta_j) + R(\Omega)$$

удовлетворяет системе уравнений, решение которой методом простых итераций сводится к чередованию двух шагов:

Е-шаг:  $g_{ij} \equiv p(j|x_i) = \text{norm}_j(w_j \varphi(x_i, \theta_j)), \quad i = 1..\ell, \quad j = 1..k;$

М-шаг:  $\theta_j = \arg \max_{\theta} \left( \sum_{i=1}^{\ell} g_{ij} \ln \varphi(x_i, \theta) + R(\Omega) \right), \quad j = 1..k;$

$$w_j = \text{norm}_j \left( \sum_{i=1}^{\ell} g_{ij} + w_j \frac{\partial R}{\partial w_j} \right), \quad j = 1..k.$$

## Регуляризация в ЕМ-алгоритме для разделения смеси

- При  $R(\Omega) = 0$  это уже знакомый нам ЕМ-алгоритм для разделения смеси вероятностных распределений
- При разделении смеси  $n$ -мерных гауссиан  $\mathcal{N}(x; \mu_j, \Sigma_j)$  регуляризация ковариационных матриц  $\Sigma_j + \tau I_n$
- $R(w) = \tau \sum_j p_j \ln w_j$  — регуляризатор сглаживания, приближает веса  $w_j$  к априорному распределению  $p_j$ :

$$w_j = \text{norm}_j \left( \sum_{i=1}^{\ell} g_{ij} + \tau p_j \right)$$

- $R(w) = -\tau \sum_j \ln w_j$  — регуляризатор разреживания, удаляет компоненты с весами  $w_j < \tau$ :

$$w_j = \text{norm}_j \left( \sum_{i=1}^{\ell} g_{ij} - \tau \right)$$



## Задача вероятностного тематического моделирования (BTM)

$W$  — конечное множество (словарь) термов (слов)

$D$  — конечное множество документов

$T$  — конечное множество тем

$X = (d_i, w_i)_{i=1}^n$  — исходные данные, *наблюдаемые переменные*

$Z = (t_i)_{i=1}^n$  — *латентные (скрытые) переменные*,  $t_i \in T$

$n_{dw}$  — частота термина  $w \in W$  в документе  $d \in D$

$\Omega = (\Phi, \Theta)$  — параметры порождающей модели  $p(X|\Omega)$

$\Phi = (\phi_{wt} = p(w|t))_{W \times T}$  — распределения слов в темах

$\Theta = (\theta_{td} = p(t|d))_{T \times D}$  — распределения тем в документах

Порождающая модель наблюдаемых и скрытых i.i.d. данных:

$$\begin{aligned} p(X, Z|\Omega) &= \prod_{i=1}^n p(d_i, w_i, t_i) = \\ &= \prod_{i=1}^n p(w_i|t_i)p(t_i|d_i)p(d_i) = \prod_{i=1}^n \phi_{w_i t_i} \theta_{t_i d_i} p(d_i) \end{aligned}$$

## Задача ВТМ: применение общего ЕМ-алгоритма

**Е-шаг:** в силу независимости элементов выборки и формулы Байеса

$$q(Z) = p(Z|X, \Omega) = \prod_{i=1}^n p(t_i|d_i, w_i) = \prod_{i=1}^n \frac{p(w_i, t_i|d_i)}{p(w_i|d_i)} = \prod_{i=1}^n \text{norm}_{t_i \in T}(\phi_{w_i t_i} \theta_{t_i d_i})$$

**М-шаг:** подставим  $q(Z)$  и  $p(X, Z|\Omega)$  в общую формулу М-шага:

$$\begin{aligned} & \sum_{Z \in T^n} q(Z) \ln p(X, Z|\Omega) + R(\Omega) = \\ & \sum_{t_1 \in T} \cdots \sum_{t_n \in T} \prod_{k=1}^n p(t_k|d_k, w_k) \sum_{i=1}^n \ln p(d_i, w_i, t_i|\Omega) + R(\Omega) = \\ & \sum_{i=1}^n \sum_{t_1 \in T} \cdots \sum_{t_n \in T} \prod_{k=1}^n p(t_k|d_k, w_k) \ln p(d_i, w_i, t_i|\Omega) + R(\Omega) = \\ & \sum_{i=1}^n \sum_{t \in T} p(t|d_i, w_i) \ln p(d_i, w_i, t|\Omega) + R(\Omega) \rightarrow \max_{\Omega} \\ & \sum_{d \in D} \sum_{w \in W} \sum_{t \in T} n_{dw} p(t|d, w) \ln(\phi_{wt} \theta_{td}) + R(\Phi, \Theta) \rightarrow \max_{\Phi, \Theta} \end{aligned}$$



## Регуляризованный ЕМ-алгоритм для задачи ВТМ

Переменные  $X = (d_i, w_i)_{i=1}^n$  наблюдаемые,  $Z = (t_i)_{i=1}^n$  латентные

**Лемма.** Точка  $\Omega = (\Phi, \Theta)$  локального максимума RML (регуляризованного маргинализованного log-правдоподобия)

$$\ln \sum_Z p(X, Z | \Omega) + R(\Omega) = \sum_{d, w} n_{dw} \ln \sum_t \phi_{wt} \theta_{td} + R(\Phi, \Theta)$$

удовлетворяет системе уравнений, решение которой методом простых итераций сводится к чередованию двух шагов:

Е-шаг:  $p(t|d, w) = \text{norm}_{t \in T}(\phi_{wt} \theta_{td}), \quad \forall (d \in D, w \in d, t \in T)$

М-шаг:  $\sum_{d, w, t} n_{dw} p(t|d, w) \ln(\phi_{wt} \theta_{td}) + R(\Phi, \Theta) \rightarrow \max_{\Phi, \Theta}$

## ЕМ-алгоритм: вывод формул М-шага

Задача М-шага декомпозируется на независимые подзадачи

$$\sum_{w,t} \ln \phi_{wt} \sum_d n_{dw} p_{tdw} + \sum_{d,t} \ln \theta_{td} \sum_w n_{dw} p_{tdw} + R(\Phi, \Theta) \rightarrow \max_{\Phi, \Theta}$$

при ограничениях  $\phi_{wt} \geq 0$ ,  $\sum_w \phi_{wt} = 1$ ,  $\theta_{td} \geq 0$ ,  $\sum_t \theta_{td} = 1$

ЕМ-алгоритм: метод простой итерации для системы уравнений

$$\begin{aligned} \text{Е-шаг:} & \quad \begin{cases} p_{tdw} \equiv p(t|d, w) = \text{norm}_{t \in T}(\phi_{wt} \theta_{td}) \end{cases} \\ \text{М-шаг:} & \quad \begin{cases} \phi_{wt} = \text{norm}_{w \in W} \left( n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right), & n_{wt} = \sum_{d \in D} n_{dw} p_{tdw} \\ \theta_{td} = \text{norm}_{t \in T} \left( n_{td} + \theta_{td} \frac{\partial R}{\partial \theta_{td}} \right), & n_{td} = \sum_{w \in W} n_{dw} p_{tdw} \end{cases} \end{aligned}$$

Воронцов К. В. Аддитивная регуляризация тематических моделей коллекций текстовых документов. Доклады РАН, 2014.

## Модель вероятностного латентного семантического анализа

**PLSA** — Probabilistic Latent Semantic Analysis [Хофманн, 1999]:

- $R(\Phi, \Theta) = 0$  — нет никакой регуляризации.

ЕМ-алгоритм: метод простой итерации для системы уравнений

$$\begin{aligned} \text{Е-шаг:} & \begin{cases} p_{tdw} = \text{norm}_{t \in T}(\phi_{wt} \theta_{td}) \end{cases} \\ \text{М-шаг:} & \begin{cases} \phi_{wt} = \text{norm}_{w \in W} \left( \sum_{d \in D} n_{dw} p_{tdw} \right) \\ \theta_{td} = \text{norm}_{t \in T} \left( \sum_{w \in W} n_{dw} p_{tdw} \right) \end{cases} \end{aligned}$$

Е-шаг — формула Байеса

М-шаг — частотные оценки условных вероятностей

---

*Hofmann T.* Probabilistic latent semantic indexing. SIGIR 1999.

## Модель латентного размещения Дирихле

LDA — Latent Dirichlet Allocation [Блэй, Ын, Джордан, 2001]:

- $$R(\Phi, \Theta) = \sum_{t \in T} \sum_{w \in W} \beta_w \ln \phi_{wt} + \sum_{d \in D} \sum_{t \in T} \alpha_t \ln \theta_{td}$$

распределения  $\phi_t$  близки к заданному распределению  $\beta$

распределения  $\theta_d$  близки к заданному распределению  $\alpha$

ЕМ-алгоритм: метод простой итерации для системы уравнений

$$\begin{aligned} \text{Е-шаг:} & \quad \begin{cases} p_{tdw} = \text{norm}_{t \in T}(\phi_{wt} \theta_{td}) \end{cases} \\ \text{М-шаг:} & \quad \begin{cases} \phi_{wt} = \text{norm}_{w \in W} \left( \sum_{d \in D} n_{dw} p_{tdw} + \beta_w \right) \\ \theta_{td} = \text{norm}_{t \in T} \left( \sum_{w \in d} n_{dw} p_{tdw} + \alpha_t \right) \end{cases} \end{aligned}$$

Blei D., Ng A., Jordan M. Latent Dirichlet Allocation. NIPS-2001. JMLR 2003.

- Широкий класс задач связан с выявлением латентных структур, порождающих наблюдаемые данные:
  - разделение смеси вероятностных распределений
  - вероятностное тематическое моделирование
  - «мягкая» и «жёсткая» кластеризация
  - сегментация временных рядов, сигналов, изображений
  - восстановление пропущенных данных
  - выявление аномальных наблюдений в данных
- Имеется рецепт для вывода вычислительных формул  $E$  и  $M$  шагов по порождающей модели  $p(X, Z|\Omega)$
- Можно добавлять какие угодно регуляризаторы  $R(\Omega)$ , причём не обязательно вероятностные вида  $\ln p(\Omega|\gamma)$
- Гарантируется сходимость в слабом смысле
- Это обучение без учителя, не требующее разметки
- В тематическом моделировании много интересных регуляризаторов (спойлер: в следующей лекции)